Πανεπιστήμιο Μακεδονίας
Τμήμα Εφαρμοσμένης Πληροφορικής
7ο εξάμηνο | Ακαδημαϊκό Έτος: 2025 – 2026

Μηχανική Μάθηση
3η Εργασία – Regression Problems

Τελική Αναφορά:

Συγκριτική Ανάλυση Αλγορίθμων Παλινδρόμησης για την Πρόβλεψη Εξέλιξης Διαβήτη

	Ον/μο	Αρ. Ακαδημαικού Μητρώου
Μέλος 1	Παρασκευούδης Στέφανος	ics23130
Μέλος 2	Παναγιωτίδης Θεόδωρος	ics22071
Μέλος 3	Παπαγιάννης Νικόλαος	ics23173
Μέλος 4	Μπλιώνα Αλίκη	ics23099

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. Εισαγωγή
   1.1. Περιγραφή Προβλήματος
   1.2. Περιγραφή Δεδομένων
   1.3. Προεπεξεργασία Δεδομένων
2. Μεθοδολογία
   2.1. Στρατηγική Επικύρωσης
   2.2. Μοντέλα Παλινδρόμησης
   2.3. Βελτιστοποίηση Παραμέτρων
   2.4. Μετρικές Αξιολόγησης
   2.5. Εργαλεία Λογισμικού & Υποστήριξη
3. Πειραματικά Αποτελέσματα
   3.1 Συγκεντρωτικός Πίνακας
   3.2 Γραφικές Παραστάσεις
      3.2.1. Σύγκριση Σχετικού Σφάλματος (MAPE)
      3.2.2. Διαγράμματα Διασποράς (Actual vs Predicted)
   3.3 Κριτική Ανάλυση Ευρημάτων
      3.3.1. Το Φαινόμενο Overfitting στον KNN
      3.3.2. Η Σταθερότητα των Gaussian Process και SVR
      3.3.3. Το Όριο της Ακρίβειας
4. Ερμηνευσιμότητα (SHAP)
   4.1 Καθολική Ερμηνεία
   4.2 Τοπική Ερμηνεία
5. Συμπεράσματα
   5.1. Βέλτιστο Μοντέλο
   5.2. Kernel vs Trees

5.3. Κλινική Χρησιμότητα

5.4. Επιβεβαίωση Μέσω SHAP

5.5. Σύγκριση με Baseline και Κλινική Αξία

6. Βιβλιογραφία

1. Εισαγωγή

1.1. Περιγραφή Προβλήματος

Η παρούσα εργασία πραγματεύεται το πρόβλημα της πρόβλεψης της ποσοτικής εξέλιξης της νόσου του διαβήτη (disease progression) σε ορίζοντα ενός έτους. Πρόκειται για ένα κλασικό πρόβλημα **Επιβλεπόμενης Μάθησης (Supervised Learning)** και συγκεκριμένα **Παλινδρόμησης (Regression)**, καθώς η μεταβλητή-στόχος είναι συνεχής και όχι κατηγορική. Στόχος είναι η ανάπτυξη και συγκριτική αξιολόγηση μοντέλων που θα μπορούν να εκτιμήσουν την επιδείνωση της υγείας των ασθενών βάσει κλινικών μετρήσεων.

1.2. Περιγραφή Δεδομένων

Για την πειραματική διαδικασία χρησιμοποιήθηκε το "Diabetes Dataset" της scikit-learn, το οποίο αποτελείται από 442 εγγραφές ασθενών. Κάθε εγγραφή περιλαμβάνει 10 χαρακτηριστικά εισόδου ενός ασθενή και μία μεταβλητή στόχο. Τα χαρακτηριστικά εισόδου είναι:

1. **Age:** Ηλικία σε έτη.
2. **Sex:** Φύλο.
3. **BMI:** Δείκτης Μάζας Σώματος.
4. **BP:** Μέση Αρτηριακή Πίεση.
5. **s1-s6:** Έξι μετρήσεις ορού αίματος.

1.3. Προεπεξεργασία Δεδομένων

- **Data Cleaning:** Έγινε έλεγχος για ελλιπείς τιμές (NaN) και διπλότυπα καθώς η ύπαρξή τους θα εμπόδιζε την εκτέλεση αλγορίθμων που βασίζονται σε matric operations.
- Εφαρμόστηκε **Min-Max Scaling** σε όλα τα χαρακτηριστικά (feature range [0, 1]).
    - Η κανονικοποίηση είναι κρίσιμη για αλγορίθμους που βασίζονται σε αποστάσεις, όπως το **Gaussian Process** και το **KNN**, που αξιοποιούνται στη συγκεκριμένη εργασία, ώστε να αποφευχθεί η κυριαρχία χαρακτηριστικών με μεγάλες τιμές στη συνάρτηση κόστους, γεγονός που θα οδηγούσε σε λανθασμένη εκπαίδευση.

2. Μεθοδολογία

2.1. Στρατηγική Επικύρωσης

Για την αξιολόγηση των μοντέλων υιοθετήθηκε η μέθοδος **6-Fold Cross Validation**.

- Η μέθοδος αυτή επιλέχθηκε έναντι του απλού Train-Test split για να εξασφαλιστεί η **γενικευσιμότητα** του μοντέλου και να μειωθεί η διακύμανση της εκτίμησης σφάλματος. Χρησιμοποιήθηκε σταθερό seed=42 για την επαναληψιμότητα των πειραμάτων.

2.2. Μοντέλα Παλινδρόμησης

Για την εκπόνηση της εργασίας χρησιμοποιήθηκαν οι εξής 4 αλγόριθμοι:

1. **Random Forest** (Ensemble Learning): Μέθοδος που βασίζεται στη συνάθροιση πολλαπλών δέντρων αποφάσεων (Bagging). Μέσω της διαδικασίας μέσου όρου, μειώνει τη διακύμανση (Variance) των μεμονωμένων δέντρων.

- *Υπερ-παράμετροι:* Εξετάστηκαν το πλήθος των δέντρων (***n_estimators: 50, 100, 200***) και το μέγιστο βάθος (***max_depth***) για τον έλεγχο της πολυπλοκότητας.

2. **Gaussian Process Regressor** (Probabilistic): Πιθανοτικό, μη-παραμετρικό μοντέλο που βασίζεται στην κατά Bayes συμπερασματολογία. Μοντελοποιεί την αβεβαιότητα των προβλέψεων.

- *Σχεδιασμός Πυρήνα (Kernel):* Χρησιμοποιήθηκε σύνθετος πυρήνας ***ConstantKernel * RBF***. Ο RBF (Radial Basis Function) επιλέχθηκε για την ικανότητά του να συλλαμβάνει μη-γραμμικές συσχετίσεις βάσει ομοιότητας.
- *Βελτιστοποίηση:* Μέσω ***RandomizedSearchCV***, ρυθμίστηκε η παράμετρος θορύβου ***alpha [0.01, 0.1, 1.0]*** για την αποφυγή overfitting.

3. **Support Vector Regression** (Kernel Method): Μοντέλο που στοχεύει στην προσαρμογή των δεδομένων εντός ενός "σωλήνα" ανοχής σφάλματος (ε-tube).

- *Υπερ-παράμετροι:* Εξετάστηκαν οι πυρήνες ***linear*** και ***rbf***, καθώς και η παράμετρος ποινής ***C*** (Regularization) που ελέγχει την ισορροπία μεταξύ απλότητας μοντέλου και σφάλματος εκπαίδευσης.

4. **K-Nearest Neighbors** (Instance-based): Αλγόριθμος lazy learning που προβλέπει την τιμή στόχο βάσει του μέσου όρου των k κοντινότερων γειτόνων στο χώρο των χαρακτηριστικών.

- *Υπερ-παράμετροι:* Εξετάστηκε το πλήθος γειτόνων ***n_neighbors [3, 5, 7, 9]*** και ο τρόπος απόδοσης βαρύτητας (***weights***: 'uniform' ή 'distance').

2.3. Βελτιστοποίηση Παραμέτρων

Για την επιλογή των βέλτιστων συνδυασμών των παραπάνω *παραμέτρων*, χρησιμοποιήθηκε η συνάρτηση RandomizedSearchCV με τις ακόλουθες ρυθμίσεις:

- ***n_iter=5:*** Για κάθε fold, το μοντέλο εκπαιδεύτηκε σε 5 τυχαίους συνδυασμούς παραμέτρων από τα παραπάνω grids.
- ***cv=3*:** Εσωτερικά (μέσα στο training set του κάθε fold), πραγματοποιήθηκε επιπλέον 3-fold cross-validation για την αξιολόγηση των παραμέτρων.
- ***n_jobs=-1*:** Χρήση όλων των διαθέσιμων πυρήνων επεξεργαστή για παράλληλη εκτέλεση και επιτάχυνση της διαδικασίας.

2.4. Μετρικές Αξιολόγησης

Για την αποτίμηση της απόδοσης των μοντέλων παλινδρόμησης αξιοποιήθηκαν οι εξής μετρικές:

1. **RMSE (Root Mean Squared Error): Τ**ιμωρεί δυσανάλογα τα μεγάλα σφάλματα. Στο πρόβλημα του διαβήτη, αυτό είναι κρίσιμο ώστε να διασφαλιστεί ότι το μοντέλο δεν θα κάνει ακραίες αποκλίσεις σε μεμονωμένους ασθενείς, οι οποίες θα ήταν κλινικά επικίνδυνες.
2. **MAE (Mean Absolute Error):** Δείχνει τη μέση απόκλιση της πρόβλεψης σε απόλυτες τιμές. Παρέχει μια **ρεαλιστική εικόνα του τυπικού σφάλματος** που αναμένεται σε κάθε ασθενή, χωρίς να επηρεάζεται υπερβολικά από ακραίες τιμές .
3. **Max Error:** Καταγράφει τη **χειρότερη δυνατή πρόβλεψη** του μοντέλου στο σύνολο ελέγχου. Χρησιμεύει ως δείκτης ασφαλείας για την αξιολόγηση της αξιοπιστίας του μοντέλου.
4. **MAPE (Mean Absolute Percentage Error):** Εκφράσει το σφάλμα ως **ποσοστό (%)**. Καθώς οι τιμές του δείκτη διαβήτη ποικίλλουν, το MAPE επιτρέπει στους κλινικούς ιατρούς να κατανοήσουν άμεσα τη **σχετική ακρίβεια** του μοντέλου, ανεξαρτήτως της κλίμακας μέτρησης του κάθε ασθενούς.

2.5. Εργαλεία Λογισμικού & Υποστήριξη

Η υλοποίηση πραγματοποιήθηκε σε γλώσσα Python (v3.x) με χρήση των βιβλιοθηκών scikit-learn, pandas, matplotlib και shap στο περιβάλλον Google Colab

3. Πειραματικά Αποτελέσματα

Στην ενότητα αυτή παρουσιάζονται τα ποσοτικά αποτελέσματα της πειραματικής διαδικασίας, όπως προέκυψαν από το Test Set μέσω της διαδικασίας 6-Fold Cross Validation.

3.1 Συγκεντρωτικός Πίνακας

Ο παρακάτω πίνακας συνοψίζει τις μέσες τιμές των μετρικών σφάλματος για κάθε αλγόριθμο (πάνω στο test set).

Μοντέλο	RMSE	MAE	MAPE (%)	Max Error
Gaussian Process	**54.985**	44.849	40.218%	**134.518**
SVR	55.291	**44.697**	**39.382%**	139.748
Random Forest	57.110	46.656	41.073%	145.330
KNN	57.586	46.569	40.310%	151.830

3.2 Γραφικές Παραστάσεις

Για την τεκμηρίωση της συμπεριφοράς των μοντέλων, παρατίθενται τα παρακάτω διαγράμματα.

3.2.1. Σύγκριση Σχετικού Σφάλματος (MAPE)

Το παρακάτω ραβδόγραμμα συγκρίνει το μέσο ποσοστιαίο σφάλμα. Παρατηρούμε ότι το **SVR** και το **Gaussian Process** επιτυγχάνουν οριακά χαμηλότερο σφάλμα (~40%) έναντι των υπολοίπων.

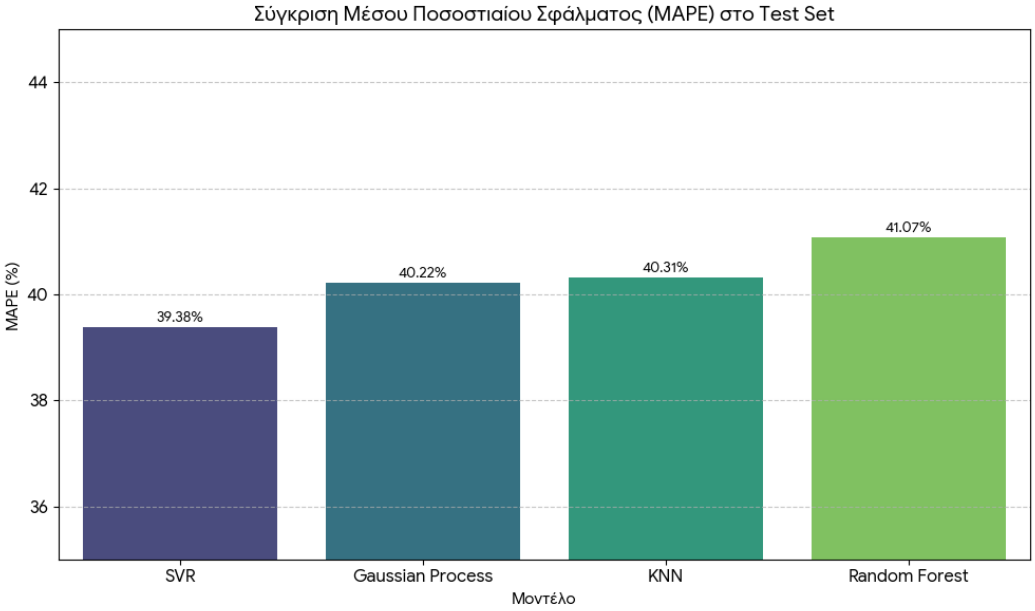

Εικόνα 1: Σύγκριση MAPE μεταξύ των τεσσάρων μοντέλων.

3.2.2. Διαγράμματα Διασποράς (Actual vs Predicted)

Η οπτική επιθεώρηση των προβλέψεων αποκαλύπτει σημαντικές διαφορές στη δομή των μοντέλων.

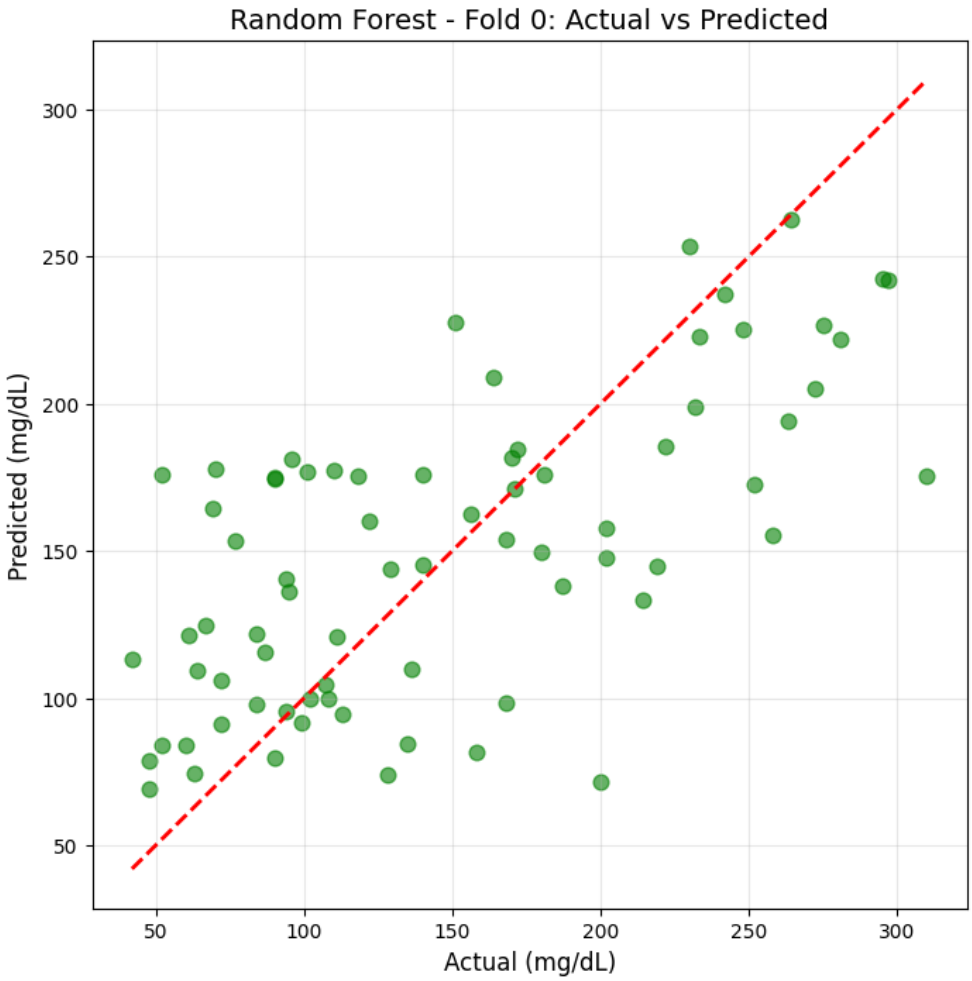

Εικόνα 2: Διάγραμμα διασποράς Random Forest (Fold 0).

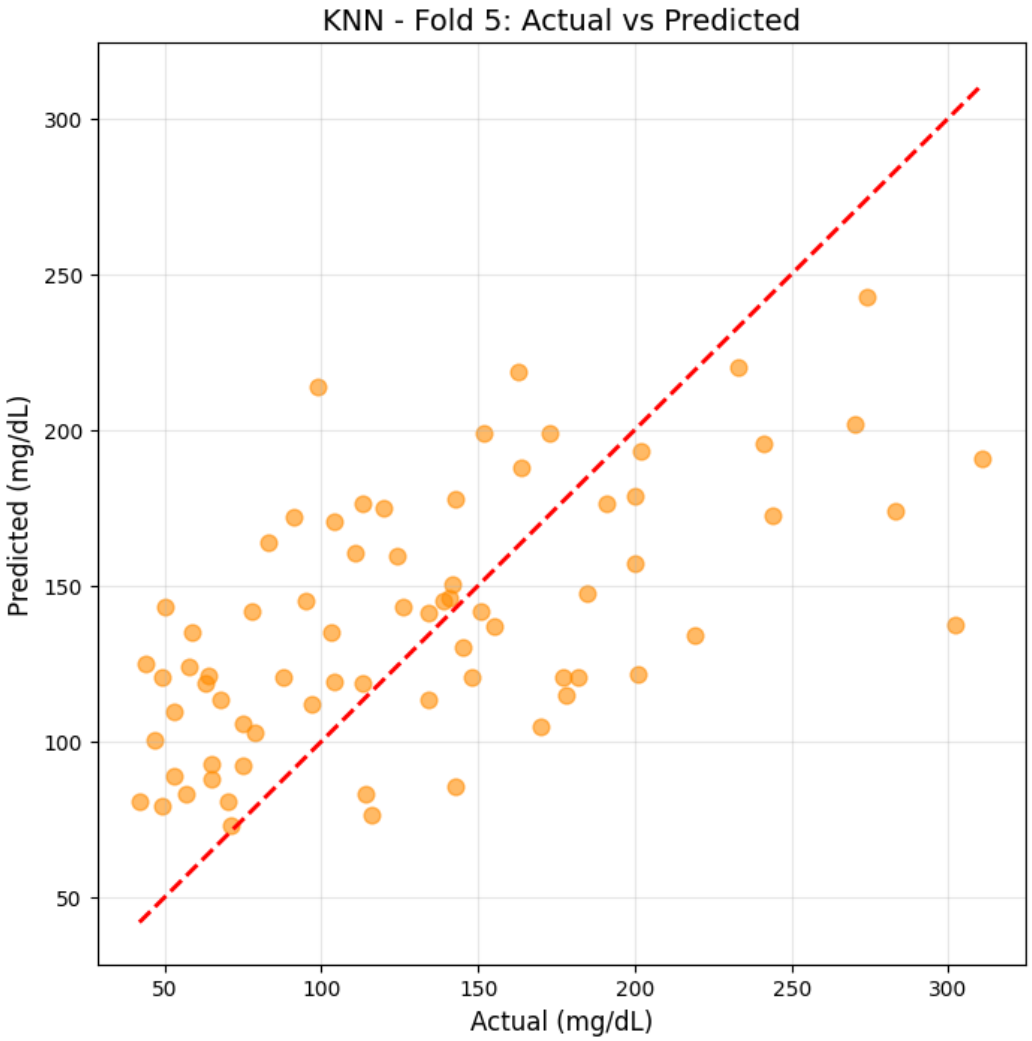

Εικόνα 3: Διάγραμμα διασποράς KNN (Fold 5). Παρατηρήση οριζόντιων γραμμώσεων.

3.3 Κριτική Ανάλυση Ευρημάτων

Η συνδυαστική μελέτη των πινάκων και των διαγραμμάτων οδηγεί στις εξής σημαντικές παρατηρήσεις:

3.3.1. Το Φαινόμενο Overfitting στον KNN

Αναλύοντας τα logs της εκπαίδευσης, παρατηρήθηκε ότι ο KNN πέτυχε σε πολλά folds μηδενικό σφάλμα στο Train Set (RMSE=0). Αυτό αποτελεί κλασική ένδειξη υπερ-προσαρμογής (Overfitting), πιθανώς διότι ο αλγόριθμος επέλεξε πολύ μικρό k ή χρήση βαρών απόστασης, με αποτέλεσμα να "απομνημονεύσει" τα δεδομένα εκπαίδευσης. Το τίμημα αυτής της συμπεριφοράς φάνηκε στο Test Set, όπου ο KNN κατέγραψε το υψηλότερο RMSE (57.58) και τη μεγαλύτερη αστάθεια (Max Error 151.83).

3.3.2. Η Σταθερότητα των Gaussian Process και SVR

Σε αντίθεση με τον KNN, τα μοντέλα GPR και SVR εμφάνισαν υψηλότερο σφάλμα στο Training, αλλά χαμηλότερο σφάλμα στο Test Set. Αυτό αποδεικνύει ότι οι μηχανισμοί κανονικοποίησης που διαθέτουν (παράμετρος alpha και C αντίστοιχα) απέτρεψαν την απομνημόνευση του θορύβου και επέτρεψαν στα μοντέλα να μάθουν την πραγματική δομή του προβλήματος.

3.3.3. Το Όριο της Ακρίβειας

Το γεγονός ότι κανένα μοντέλο δεν κατάφερε να μειώσει το MAPE κάτω από ~39% υποδηλώνει ότι υπάρχουν πιθανώς βιολογικοί παράγοντες, που επηρεάζουν την εξέλιξη του διαβήτη και δεν περιλαμβάνονται στα 10 χαρακτηριστικά του dataset, θέτοντας ένα ανώτατο όριο στην ακρίβεια που μπορεί να επιτευχθεί υπολογιστικά.

4. Ερμηνευσιμότητα (SHAP)

Για την ερμηνεία των μοντέλων χρησιμοποιήθηκε η θεωρία παιγνίων μέσω της βιβλιοθήκης **SHAP:**

4.1 Καθολική Ερμηνεία

Το Summary Plot ιεραρχεί τα χαρακτηριστικά βάσει της επίδρασής τους.

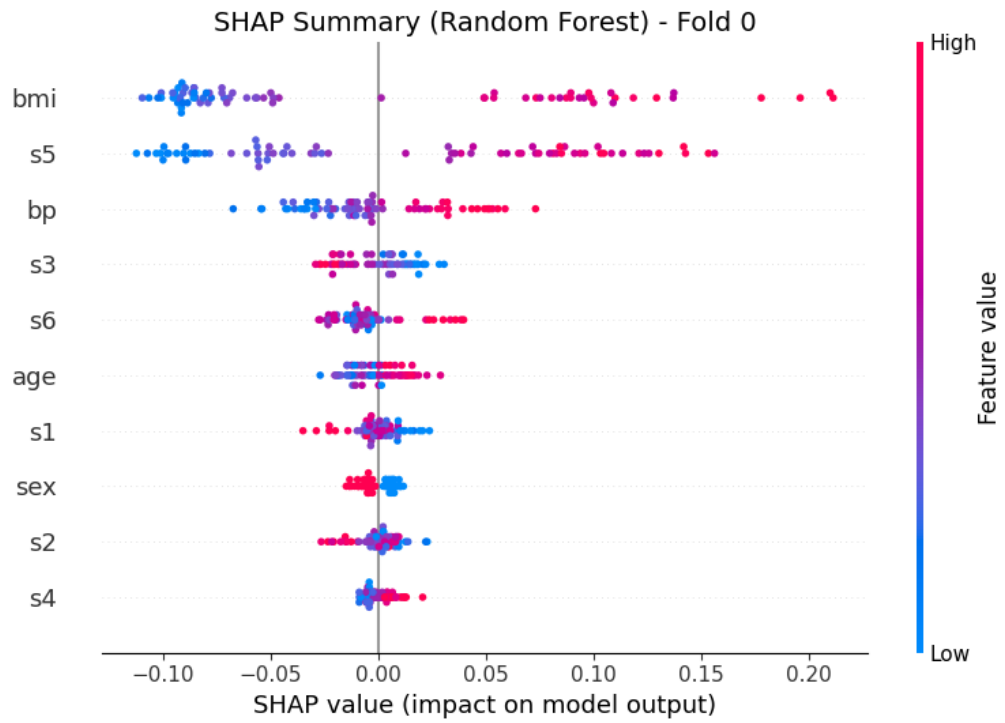

Εικόνα 4: SHAP Summary Plot (fold 0).

Ανάλυση: Το γράφημα επιβεβαιώνει ότι το μοντέλο έμαθε σωστά ιατρικά πρότυπα. Το **BMI** (Δείκτης Μάζας Σώματος) και ο δείκτης **s5** είναι οι κυρίαρχοι παράγοντες. Η θετική συσχέτιση (κόκκινα σημεία δεξιά στον άξονα) δείχνει ότι η αύξηση του βάρους επιδεινώνει την πρόγνωση.

4.2 Τοπική Ερμηνεία

Το Waterfall Plot αναλύει την πρόβλεψη για έναν συγκεκριμένο ασθενή.

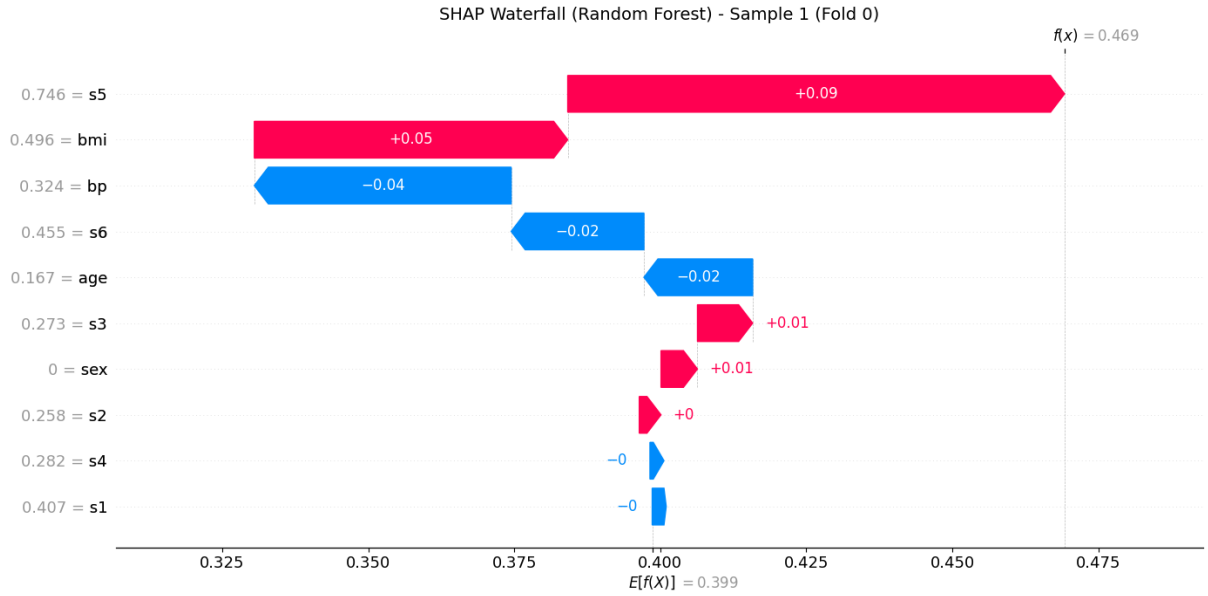

Εικόνα 5: SHAP Waterfall Plot (fold 0).

Ανάλυση: Στο συγκεκριμένο παράδειγμα, βλέπουμε ότι παρόλο που η ηλικία (age) λειτούργησε προστατευτικά (μπλε μπάρα), η υψηλή τιμή του **BMI** και του **s5** υπερίσχυσαν, ωθώντας την τελική πρόβλεψη προς τα πάνω.

5. Συμπεράσματα

Η συγκριτική μελέτη των αλγορίθμων παλινδρόμησης για την πρόβλεψη του διαβήτη κατέληξε στα εξής συμπεράσματα:

5.1. Βέλτιστο Μοντέλο

Το **Gaussian Process** αναδείχθηκε ως η πιο αξιόπιστη επιλογή. Προσφέρει τον καλύτερο συνδυασμό χαμηλού μέσου σφάλματος (RMSE 54.98) και ασφάλειας έναντι ακραίων αστοχιών (χαμηλότερο Max Error), υπερτερώντας των ευριστικών μεθόδων.

5.2. Kernel vs Trees

Τα μοντέλα πυρήνα (GPR, SVR) υπερείχαν ελαφρώς των δενδρικών μεθόδων (Random Forest) και των μεθόδων γειτνίασης (KNN), οι οποίες εμφάνισαν τάσεις υπερ-προσαρμογής.

5.3. Κλινική Χρησιμότητα

Η εισαγωγή της μετρικής **MAPE** ήταν καθοριστική για την κατανόηση του σχετικού σφάλματος της τάξης του 40%, γεγονός που υποδεικνύει ότι μοντέλα κρίνονται χρήσιμα για την εκτίμηση της τάσης, αλλά απαιτούνται περισσότερα δεδομένα για ακριβή κλινική πρόγνωση.

5.4. Επιβεβαίωση Μέσω SHAP

Η ανάλυση ερμηνευσιμότητας επιβεβαίωσε την κλινική γνώση ότι οι προβλέψεις βασίζονται σε έγκυρους βιολογικούς δείκτες (BMI, s5) και όχι σε τυχαίες συσχετίσεις, ενισχύοντας την εμπιστοσύνη στη χρήση αλγορίθμων Μηχανικής Μάθησης στον ιατρικό τομέα.

5.5. Σύγκριση με Baseline και Κλινική Αξία

Είναι σημαντικό να σημειωθεί ότι η τυπική απόκλιση του dataset είναι περίπου 77 mg/dL. Επομένως, ένα απλοϊκό μοντέλο (Dummy Regressor) που θα προέβλεπε σταθερά τη μέση τιμή, θα είχε RMSE περίπου 77. Το μοντέλο Gaussian Process πέτυχε RMSE περίπου 55, προσφέροντας βελτίωση της τάξης του **~28.5%** σε σχέση με την τυχαία πρόβλεψη. Αυτό αποδεικνύει ότι, παρά τον υψηλό θόρυβο των δεδομένων, οι αλγόριθμοι κατάφεραν να εξάγουν σημαντική πληροφορία από τα κλινικά χαρακτηριστικά, προσδίδοντας ουσιαστική αξία στην ιατρική πρόγνωση.

6. Βιβλιογραφία

1. Λογισμικό & Βιβλιοθήκες (Online Documentation)

- **Scikit-learn Developers.** (2024). *Scikit-learn: Machine Learning in Python – User Guide*. Διαθέσιμο στο: https://scikit-learn.org/stable/user_guide.html
- **The Pandas Development Team.** (2024). *pandas: powerful Python data analysis toolkit – Documentation*. Διαθέσιμο στο: https://pandas.pydata.org/docs/
- **Matplotlib Development Team.** (2024). *Matplotlib: Visualization with Python – User Guide*. Διαθέσιμο στο: https://matplotlib.org/stable/users/index.html
- **Lundberg, S. M.** (2024). *SHAP (SHapley Additive exPlanations) Documentation*. Διαθέσιμο στο: https://shap.readthedocs.io/en/latest/

2. Υλικό Διαλέξεων & Εργαστηρίων Μαθήματος

- **Διάλεξη 02 & 03** (Data Preprocessing):
  - Τεχνικές καθαρισμού δεδομένων (dropna για NaN values).
  - Θεωρία κανονικοποίησης (Min-Max Scaling) και η αναγκαιότητά της για αλγορίθμους απόστασης (KNN, GPR).
- **Διάλεξη 05** (Validation Strategy):
  - Η έννοια του Generalization Error και του Bias-Variance Tradeoff.
  - Η εφαρμογή του K-Fold Cross Validation.
- **Διάλεξη 08** (Hyperparameter Optimization):
  - Η χρήση του RandomizedSearchCV για την εύρεση βέλτιστων υπερ-παραμέτρων (alpha, n_neighbors, C).
- **Διάλεξη 09** (Explainability):
  - Εισαγωγή στα "Black Box" μοντέλα και η ανάγκη για ερμηνευσιμότητα.
  - Η χρήση της βιβλιοθήκης SHAP (Summary & Waterfall plots) για την κατανόηση της σημαντικότητας των χαρακτηριστικών.
- **Εργαστήριο 3** (Regression):
  - Βασικός κώδικας φόρτωσης του Diabetes Dataset.
  - Παραδείγματα χρήσης των μετρικών αξιολόγησης (RMSE, MAE)

3. Εργαλεία Τεχνητής Νοημοσύνης

Η χρήση εργαλείων Παραγωγικής Τεχνητής Νοημοσύνης (Generative AI) επικουρικά για τους εξής σκοπούς:

- **Βελτιστοποίηση Κώδικα:** Υποβοήθηση στη σύνταξη των scripts για την αυτοματοποιημένη παραγωγή των διαγραμμάτων (SHAP plots).
- **Αποσφαλμάτωση Κώδικα:** Εντοπισμός και διόρθωση σφαλμάτων στον κώδικα Python
- **Γλωσσική Επιμέλεια:** Βελτίωση της ορολογίας στην τεχνική αναφορά.

Τονίζεται ότι η σχεδίαση της μεθοδολογίας, η εκτέλεση των πειραμάτων και η εξαγωγή των συμπερασμάτων αποτελούν πρωτότυπη πνευματική εργασία των μελών της ομάδας.